

АННОТАЦИЯ

Предрелизная подготовка в системе MarLine

Автор:	Овечкин Андрей
Научный руководитель:	Гориховский Вячеслав Игоревич
Консультант:	Дмитриевцев Алексей Сергеевич
Репозиторий:	https://github.com/Iseyne/marline-reports
Дата:	4 октября 2026

1. Аннотация

MarLine — система дедупликации, построенная на границах, зависящих от содержимого. Данные нарезаются на чанки, для каждого считаются признаки подобия, похожие фрагменты собираются в кластеры и кодируются как дельты относительно базового. Разработка идёт силами учебной команды и охватывает шесть крейтов: построение эскизов, индекс с эвристическим отбором кандидатов, кластеризацию, кодировщики дельт, хранилище на `chunks` и отдельный Palantir-конвейер.

Основная проблема сейчас даже не в алгоритмах. Модульных тестов достаточно много, 281 штука, и подавляющее большинство приходится на кодировщики и индекс, но end-to-end тестов нет вообще, а у бинарника `marline` тестов нет вовсе. Интеграционных файлов три, и полный конвейер они не покрывают. Получается, что каждая функция проверена по отдельности, но то, что все стадии правильно собираются в один прогон по реальному файлу, не подтверждено ничем.

Попутно вылезло несколько вещей, из-за которых релиз в текущем виде невозможен. Коэффициенты хеша признаков берутся из генератора случайных чисел, поэтому два одинаковых запуска дают разные хеши и результаты бенчмарков между собой не сравниваются. Конфигурационная сетка в `palantir_metrics` настроена, но фактически не применяется: все варианты сводятся к одному, а метрика дедупликации задана константой независимо от данных. Пример быстрого старта в README не компилируется, и никто этого не замечает, потому что README не подключён к документации и не проверяется doc-тестами. Ни в одном крейте не заполнены поля, которые нужны `cargo` для публикации.

Цель работы — довести проект до состояния, в котором его можно нормально выпустить.

Результатом планируется набор интеграционных и end-to-end тестов, закрывающих полный цикл от нарезки до дедупликации, исправление найденных дефектов и приведение документации в порядок — с рабочими примерами вместо тех, что не компилируются. Отдельно стоит вопрос с зависимостями: внешний `chunkfs` подключён по адресу `git` без фиксации ревизии, поэтому ее версия может смениться без нашего участия, и сборка станет невоспроизводимой сама по себе.

2. Что уже проверено

Обследование кода показало следующее.

Крейт	Модульные	Интеграционные	End-to-end
<code>marline_index</code>	80	0	0
<code>marline_scrub</code>	165	7	0
<code>marline_palantir</code>	19	2	0
<code>marline_sketcher</code>	8	0	0
<code>marline</code>	0	0	0
<code>marline_delta</code>	0	0	0
Итого	281	9	0

Модульное тестирование для алгоритмической части сделано неплохо,

и трогать его не нужно. Проблема в другом: каталог `marline_delta` пустой, непонятно, зачем он вообще нужен, а поведение собранного бинарника не проверяет ни один тест.

Сценарий непрерывной интеграции тоже стоит расширить. Сейчас он срабатывает только на `push`, из-за чего ветку с `pull request` можно слить, не дождавшись проверок, и в нём нет ни `cargopublish - -dry-run`, ни сборки документации, которая бы поймала неработающие ссылки.

3. Направления работы

- Сделать поведение системы проверяемым: тесты на полный цикл работы конвейера и на восстановление данных без потерь.
- Убрать недетерминизм, иначе любые замеры теряют смысл.
- Привести в порядок документацию так, чтобы примеры собирались и проверялись автоматически.
- Почистить репозиторий и настроить CI так, чтобы сбой проверок останавливал выпуск релиза.